



Kauno technologijos universitetas

Informatikos fakultetas

Modulis „Tiriamasis projektas 1“

**Projektas: Kompiuterinės regos ir mašininio mokymosi
pritaikymo tyrimas pramoninės gamybos gaminijų kokybės
patikrai**

Projektavimo metodologijos ir technologijų analizė

IFM 9/2 gr. Algirdas Kartavičius

Studentas

Doc. Mantas Lukoševičius

Projekto vadovas

Lekt. Virginija Limanauskienė

Dėstytoja

Kaunas, 2019

Turinys

Lentelių sąrašas	3
Paveikslų sąrašas	4
Santrumpų ir terminų sąrašas	5
Įvadas.....	6
1. Tikslas	7
2. Srities apžvalga	8
2.1. Techninė įranga ir jos apribojimai.....	8
3. Gaminių su defektais iš nuotraukų atpažinimo metodai bei technologijos.....	11
3.1. Tradiciniai vaizdo apdorojimo metodai.....	11
3.2. Mašininio mokymosi sprendimai defektų aptikimui	13
3.2.1. SVM metodo pritaikymas defektų tipo nustatymui.....	14
3.2.2. Konvoluciinių neuroninių tinklų taikymas defektų aptikimui ir klasifikavimui	15
3.2.3. „Kaggle“ platformos apžvalga	18
4. Egzistuojančių rinkoje sistemų savybių palyginimas.....	19
Išvados	21
Literatūros sąrašas	22

Lentelių sąrašas

1 lentelė Konvoluciinių neuroninių tinklų ir atraminių vektorių klasifikatoriaus palyginimas	16
2. lentelė Žmogaus vizualinės patikros bei tyrimo aprašyto metodo palyginimas	17
3 lentelė. „ColourBrain“ ir „Argos Grading System“ sistemų palyginimas [22], [23], [24]	19

Paveikslų sąrašas

2.1 pav. Linijos nuskaitymo kameros veikimo schema [6].....	9
3.1 pav. Tinklinių skaičiavimų (angl. Grid computing) schema [13]	13
3.2 pav. Baldų detalių pagrindinių paviršių bei kraštų paviršių defektais, UAB Elinta nuotrauka...	14
3.3 pav. Butelių pažeidimų atpažinimo metodas [2].....	16
3.4 pav. Baldų detalės su ryškia tekštūra, UAB Elinta nuotrauka	17
3.5 pav. Plieno paviršiaus defektais [15]	18

Santrumpų ir terminų sąrašas

Santrumpos:

KNN (angl. Convolutional neural network) – konvoliuciniai neuroniniai tinklai.

MM (angl. Machine learning) – mašininis mokymasis.

SVM (angl. Support vector machine) – atraminių vektorių klasifikatorius.

MDF (angl. Medium-density fibreboard) – vidutinio tankio medienos plaušų plokštė.

Terminai:

Kraštų aptikimas – (angl. Edge detection) vaizdo apdorojimo technika, kuri naudojama objektų kraštų aptikimui vaizde.

Morfologinės transformacijos – (angl. Morphological transformations) vaizdo apdorojimo operacijos, kurios skirtos pakeisti objektų formą vaizde.

Kompiuterinė rega – (angl. Computer vision) tarpdisciplininė mokslo sritis, kuri siekia gauti tam tikrą informaciją apdorojant skaitmeninį vaizdą. Dažniausiai naudojama užduočių automatizavimui.

Tinkliniai skaičiavimai – (angl. Grid computing) paskirstyta architektūra, kur didelis skaičius kompiuterių yra sujungti ir dalinasi savo resursais, norint išspręsti sudėtingą problemą.

Vidutinio tankio medienos plaušų plokštė – (angl. Medium-density fibreboard) medienos inžinerijos produktas, gaminamas sumaišant į plaušus susmulkintą medieną, vašką ir dervą. Plokštės yra formuojamos naudojant aukštą temperatūrą ir spaudimą.

Prižiūrimas mokymasis - (angl. Supervised learning) mašininio mokymosi tipas, kurio užduotis išmokti funkciją, pagal kurią įvestis ir išvestis yra susiejama remiantis įvesties ir išvesties porų pavyzdžiais.

Medienos mazgas – (angl. Wood knot) tai matomas trūkumas medienos pluošte, kuris yra tamsesnis nei mediena esanti aplink ji.

Neprižiūrimas mokymasis – (angl. Unsupervised learning) mašininio mokymosi tipas, kuris nustato nežinomus šablonus be išankstinės anotacijos.

Linių nuskaitymo kamera – (angl. Line scan camera) kamera, kurios jutikli sudaro tik viena eilutę pikselių. Šios kameros naudojamos aukštos skiriamosios gebos vaizdų gavimui, norint gauti vaizdą reikia linijiniu judesiu judinti kamerą arba objektą.

Įvadas

Pramoninė gamyba yra labai svarbi šiuolaikinėje visuomenėje, kadangi beveik visi mus supantys daiktai ir įrenginiai yra pagaminti, naudojantis pramoninės gamybos technologijomis. Robotai bei kiti gamybos įrenginiai pagreitina bei palengvina gamybą, tačiau šie įrenginiai neužtikrina gaminių kokybės, todėl sugedus tam tikrai įrenginio detalei gali nutikti nemalonų pasekmių – stipriai padidėti gaminių su defektais kiekis. Netinkamų gaminių gamyba stipriai sumažina pelną, sumažina gamybos apimtis, padidina žaliavų sąnaudas, padidina sąlygas ekologinių problemų vystymuisi (pvz. iškertama daugiau medžių arba papildomai sunaudojama daugiau elektros energijos). Automatizuota gamybos kokybės kontrolė leidžia išvengti šių problemų. Naudojantis šia technologija galima pakeisti žmones ne tik gamybos veiksmų atlikime, bet ir kokybės užtikrinime. Gaminių kokybės patikra yra svarbi, nes leidžia greičiau identifikuoti iškilusias problemas, sumažina gamybos išlaidas, eliminuoja brangias klaidas. Taip pat automatizuota patikra leidžia objektyviai įvertinti gaminio kokybę ir išvengti žmogiškųjų klaidų. Darbe aprašoma gaminių kokybės patikra, vykdoma pasitelkiant kompiuterinės regos įrangą ir vaizdo apdorojimo bei mašininio mokymosi metodus. Darbe planuojama įsigilinti į paviršiaus defektų aptikimą pramoninių gaminių gamyboje nemažai dėmesio skiriant baldų detalių kokybės įvertinimo metodams, kadangi baldų gamyba bene stambiausia Lietuvos pramonės sritis. Svarbiausia darbo dalis – mašininio mokymosi algoritmu, kurie labiausiai tinkami defektų aptikimui bei defekto tipo nustatymui (klasifikavimui), tyrimas. Taip pat planuojama nemažai dėmesio skirti ne tik mašininio mokymosi metodų tikslumui, bet ir jų vykdymo laikui, kadangi gaminių kokybės patikros procesas vyksta realiu laiku bei reikia apdoroti gana didelį informacijos (nuotraukų) kiekį.

Raktiniai žodžiai: Kompiuterinė rega, mašininis mokymasis, kokybės patikra, pramonės automatizavimas, defektų aptikimas bei klasifikavimas.

Keywords: computer vision, machine learning, quality control, industrial automation, defects detection and classification

1. Tikslas

Šio darbo tikslas yra surasti ir ištirti kompiuterinės regos bei mašininio mokymosi metodus, kurie leis identifikuoti baldų detalių paviršiaus defektus ir juos klasifikuoti. Netinkamos produkcijos nustatymas leis padidinti pramoninės gamybos efektyvumą, sumažins gamybos išlaidas bei žaliavų sunaudojimą. Šis baldų detalių gamybos kokybės užtikrinimas gamintojams leis greičiau plėstis, padidinti pelną beiapti labiau konkurencingiems.

Šio darbo tikslas yra surasti ir ištirti labiausiai tinkamus metodus ir atlikus tyrimus bei eksperimentus planuojamą gautą rezultatą panaudoti realiose baldų detalių gamybos linijoje.

2. Srities apžvalga

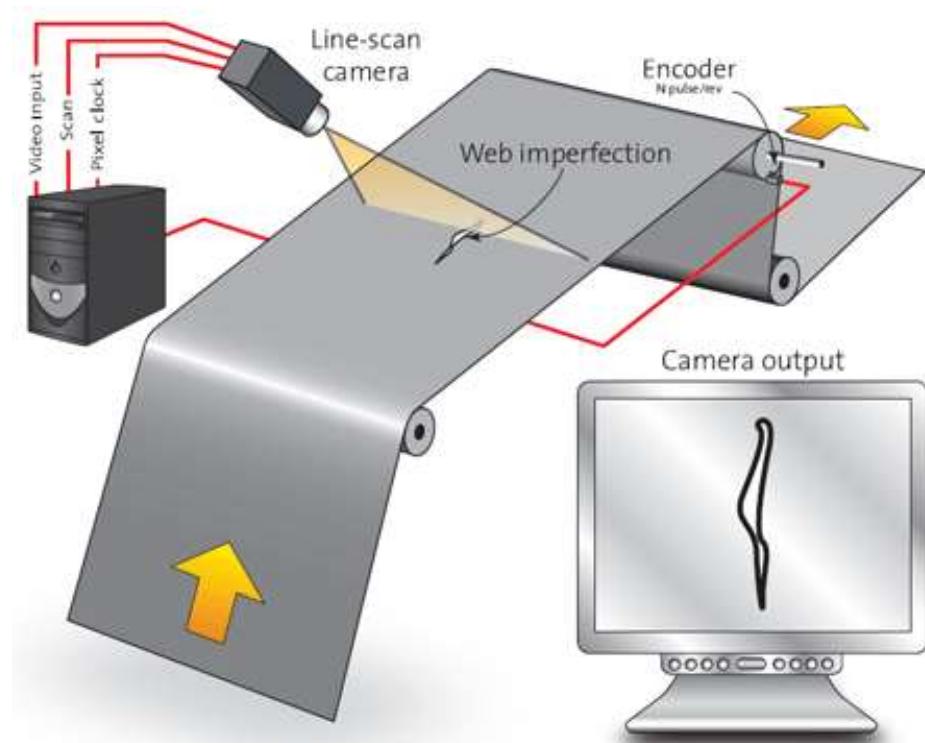
Automatizacija ir robotizacija šiuo metu yra labai svarbios, kadangi jų pagalba galima padidinti gamybos patikimumą, saugumą, pagerinti gaminių kokybę, sumažinti žaliavų švaistymą bei padidinti pelningumą. Taip pat automatizacija leidžia palengvinti žmonių darbą. Dažniausiai žmonės nemégsta pasikartojančių, neįdomių užduočių. Pramoninės gamyklos dažniausiai dirba keliomis pamainomis, todėl žmonėms dažnai tenka dirbtai naktį. Varginantis bei naktinis darbas sumažina žmonių darbo efektyvumą, todėl padidėja klaidų tikimybė. Šios klaidos dažnai lemia medžiagų sugadinimą ar net naudojimui netinkamą galutinį produktą. Tuo tarpu, automatizuotų sistemų šie veiksnių neveikia, kadangi jos yra sukurtos atlikti pasikartojančius veiksmus, šios sistemos nepavargsta bei jiems neturi įtakos naktinis darbas. Dar vienas didelis automatizuotų sistemų pranašumas – jos gali dirbtai ekstremaliomis sąlygomis. Nemažai pramoninių procesų yra atliekama aplinkoje, kuri nėra įprasta žmogui (labai karšta arba labai šalta, labai triukšminga aplinka), todėl darbus tokiomis sąlygomis žmonėms yra ypač sunku atlikti arba kartais net ir neįmanoma. Dėl šios priežasties yra labai svarbu stengtis pritaikyti automatizuotas sistemas darbui ekstremaliomis sąlygomis [1].

Nors šios automatizuotos sistemos turi labai daug privalumų lyginant su žmonių darbu, tačiau jos turi ir keletą trūkumų. Automatizuotos sistemos dažnai yra labai sudėtingos ir susideda iš daugybės komponentų, todėl yra gana didelė tikimybė, kad tam tikras komponentas suges. Toks gedimas gali turėti labai rimtų padarinių – visi pagaminti produktai bus su defektais ir bus iššvaistyta dar daugiau žaliavų. Šios rimtos problemos galima išvengti panaudojant kompiuterinės regos sprendimus, kurie užtikrina gaminių kokybę bei stabdo gamybos procesą, jei tam tikras netinkamų produktų kiekis pagaminamas iš eilės. Taip pat kompiuterinės regos sistemos informuoja žmones apie netinkamos kokybės gaminius bei dažnai identifikuja defektų rūšį bei jų kilmės šaltinį. Kompiuterinės regos sistemos yra grįstos iš kamerų gauto vaizdo apdorojimu, naudojant vaizdo apdorojimo algoritmus arba taikant mašininio mokymosi metodus. Vizualinės patikros privalumai pramoninėje gamyboje yra labai ženklūs, nes produktų kiekiai yra labai dideli ir net nedidelis kokybės pagerinimas leidžia surauputi daug pinigų. Kompiuterine rega pagrįsti produktų patikros metodai yra plačiai ištirti ir naudojami pagerinti produktų kokybę bei sumažinti išlaidas [2]. Beveik visada pramoninių gaminių kokybės patikra vyksta realiu laiku [3], [4], todėl reikia ne tik analizuoti gautą iš nuotraukų vaizdą, bet ir užtikrinti, kad gaunamas vaizdas būtų kokybiškas ir tinkamas defektų aptikimui. Šiame skyriuje aptarsime svarbiausias problemas susijusias su vaizdo gavimu realiu laiku.

2.1. Techninė įranga ir jos apribojimai

Igyvendinant kompiuterinės regos sprendimus galima panaudoti įvairias kameras ar jutiklius. Nesudėtingoms užduotims atlikti galima pritaikyti išmaniasias kameras (angl. Smart camera) – tai industrinė vaizdo kamera, kuri turi integruotą vaizdo apdorojimo sistemą ir gali veikti be papildomo kompiuterio. Kitas populiarus kamerų tipas yra regiono nuskaitymo kameros (angl. Area scan camera). Šios kameros dažniausiai naudojamos tradiciniams uždaviniams spręsti, tačiau jos labiausiai tinkamos, kai objektas bent trumpam nejuda ir nėra labai didelis. Kuriant pramoninius kompiuterinės regos spendimus dažnai susiduriamu su netradicinėmis problemomis, todėl šioms problemoms spręsti yra naudojamos linijos nuskaitymo kameros (angl. Line scan camera). Norint nuskaityti vaizdą su šia kamera reikia linijiniu judesiui judinti pačią kamerą arba pravežti objektą konvejeriu (dažniausiai pramoniniai gaminiai visos gamybos metu juda konvejeriu). Linijos nuskaitymo kameros naudoja vieną pikselių eilutę, todėl jos nėra apribotos tam tikros vertikalios skiriamosios gebos ir gali nuskaityti daug didesnius vaizdus nei regiono nuskaitymo kameros.

Analizės metu nustatyta, kad vienas iš plačiai taikomų kompiuterinės regos metodų yra tekstilės kokybės patikra. Dažniausiai tekstilės medžiaga yra 1-3m pločio ir juda nuo 20 iki 200 m/min greičiu [5], todėl tik didelės raiškos ir dideliu greičiu veikiančios kameros gali užfiksuoti vaizdą, tinkamą visų defektų aptikimui. Dažniausiai linijos nuskaitymo kamerų rezoliucija yra tarp 512 ir 12888 pikselių [6], todėl galima identifikuoti net mažiausius medžiagos pažeidimus. Linijos nuskaitymo kameros veikimo principas pavaizduotas **2.1 pav.** [6] Linijos nuskaitymo kamerų veikimo principas pagrįstas objekto judėjimu, todėl reikia žinoti kokiui greičiu juda tam tikra medžiaga ar objekto ant konvejerio, kadangi tik tada gaunamas vaizdas bus tikslus ir tinkamas. Linijinių kamerų naudojimo privalumus patvirtina ir vieno populiariausią baldą detalių patikros sistemų patentas. Šiame patente kai didžiausias privalumas pabrėžiamas, kad naudojant daugiau kamerų kiekvienos kameros regos laukas yra mažesnis, todėl galima sumažinti atstumą nuo kameros iki objekto, o tai stipriai sumažina vibracijų įtaką bei leidžia naudoti paprastesnius bei pigesnius kamerų objektyvus [7]. Linijos greičio nustatymui yra naudojami impulsų generavimo įrenginiai (angl. Incremental encoder), kurie sukdamiesi generuoja impulsus. Sugeneruotų impulsų skaičius priklauso nuo linijos greičio, todėl tinkamas vaizdas gaunamas net ir tuo atveju, kai linijos greitis kinta.



2.1 pav. Linijos nuskaitymo kameros veikimo schema [6]

Kitas didelis linijos nuskaitymo kameros privalumas, kad norint pastebėti tam tikrus defektus užtenka tolygiai apšvesti siaurą ruožą, į kurį yra nukreipta kamera, o naudojant regiono nuskaitymo kameras reikia apšvesti visą objekto plotą. Tolygiai apšvesti visą objektą yra gana sudėtinga, o kartais ir sunkiai įgyvendinama užduotis (nėra pakankamai vietos įmontuoti apšvetimą). Netolygiai apšvietus objektą regiono nuskaitymo kameros nuskaitys vaizdą, kuris bus netinkamas defektų identifikavimui, kadangi vaizdas šonuose bus šonuose bus tamšesnis, o centre per daug šviesus. Netolygus vaizdas neleis užtikrinti visų defektų aptikimo ir identifikavimo. Naudojant linijos nuskaitymo kamerą lengviau pastebėti defektus ir dėl to, kad šie defektai dažnai matomi tik apšvietus objektą tam tikru kampu, o siauro šviesos šaltinio kampas yra žymiai lengviau reguliuojamas nei apšvetimas, naudojamas regiono nuskaitymo kameroms. Apšvetimo sąlygos yra labai svarbios vizualinės

patikros sistemose, kadangi tik paviršiaus charakteristikas atitinkantis apšvietimas leis gerai aptikti defektus [8].

Įgyvendinant kompiuterinės regos sprendimus produkcijos kokybei užtikrinti yra susidurama ne tik su aukščiau paminėtomis problemomis dėl gaminių judėjimo greičio ar didelių matmenų, bet ir su problema dėl gaminių su tekstūromis. Šios tekstūros dažnai labai panašios į defektus, todėl stipriai apsunkina netinkamų vietų aptikimą bei sumažina kokybės patikros sistemų patikimumą. Tekstūros bei spalvos įtaką galima sumažinti naudojant šviesos šaltinį, kurio bangos ilgis (700 nm – 2500 nm) yra artimas infraraudonujų spindulių ilgiui (angl. Near infrared). Analizės metu nustatyta, kad artimi infraraudonų spindulių spektrui šviesos šaltiniai yra gana plačiai taikomi vaisių bei daržovių paviršiaus defektų identifikavimui. Toks apšvietimas leidžia taikyti tą patį defektų aptikimo algoritmą skirtingos spalvos bei tekstūros vaisiams. [9] Taip pat stipriai sumažina tekstūros įtaką ir leidžia padidinti defektų aptikimo patikimumą.

3. Gaminij su defektais iš nuotraukų atpažinimo metodai bei technologijos

Pritaikius tinkamą apšvietimą ir pasirinkus tinkamas kameras gaunamas vaizdas, kuriame matosi defektai, tačiau defektų aptikimas nėra toks paprastas, kaip gali pasirodyti iš pirmo žvilgsnio. Analizės metu pavyko rasti nemažai informacijos apie plieno paviršiaus defektų aptikimo metodus. Baldų detalių paviršiaus defektų aptikimo principas yra labai panašus į plieno lakštų paviršiaus defektų aptikimą, todėl nemažai dėmesio bus skiriama plieno kokybės patikrai. Kitas labai svarbus defektų aptikimo kriterijus yra aptikimo metodų veikimo laikas. Dažniausiai patikra vyksta realiu laiku, todėl analizė turėtų užtrukti kuo trumpesnį laiką. Šis aprūpojimas neleidžia naudoti metodų, kurie pasižymi geresniais rezultatais, tačiau užtrunka per ilgai.

Analizės metu nustatyta, kad galima taikyti kelis skirtinges defektų aptikimo metodus. Vienas iš jų, kai pirmiausiai aptinkami galimi defektų regionai naudojant vaizdo segmentavimą ir tik tada naudojami defektų klasifikavimo metodai, norint patvirtinti, ar tai tikrai defektas ir nustatyti defekto tipą [10]. Kitas gana populiarus metodas yra Atraminij vektorių klasifikatorius. Šis metodas leidžia realiu laiku nustatyti komplikuotus defektų šablonus užtikrinant didelį efektyvumą. [3] Šiuo metu kompiuterinės regos problemoms spręsti dažnai taikomi konvoluciiniai neuroniniai tinklai. Ši mašininio mokymosi rūšis turi nemažai privalumų lyginant su tradiciniais vaizdo apdorojimo metodais ar tradiciniais mašininio mokymosi metodais. Vienas KNN gali būti naudojamas tikrinti produktų su tekštūra ir be tekštūros paviršiaus defektams, o tradiciniai mašininio mokymosi metodai dažniausiai yra pritaikomi skirtini priklausomai nuo produktų paviršiaus tekštūros [11].

3.1. Tradiciniai vaizdo apdorojimo metodai

Vaizdo apdorojimui yra daug metodų bei technologijų. Vieni iš seniausių, tačiau vis dar plačiai naudojamų, yra tradiciniai vaizdo apdorojimo metodai, kurie nenaudoja MM. Po to kai vaizdas gaunamas iš kameros jis yra apdorojamas pagal tikrą nustatytą vaizdo apdorojimo algoritmu seką ir atliskus visus veiksmus gaunamas norimas rezultatas.

Dažniausiai taikomi yra šie vaizdo apdorojimo metodai:

- Morfologinės transformacijos;
- Vaizdo segmentavimas;
- Vaizdo slenkstinės vertės nustatymas;
- Kraštų aptikimo algoritmai;
- Teksto atpažinimas (angl. Optical character recognition);
- Šablonų aptikimas (angl. Pattern recognition).

Taikant šiuos vaizdo apdorojimo algoritmus galima nustatyti tam tikras vaizdo objektų savybes, kurios skiriasi nuo viso objekto ir tai galima identifikuoti kaip defektą, tačiau tikrinant objektus, kurie nėra vienspalviai arba turi tam tikrą tekštūrą šis paprastas metodas nėra patikimas, kadangi dažnai defektai atrodo panašiai, kaip tam tikri tekštūros elementai. Šie metodai turi daug privalumų lyginant su žmogaus kokybės patikra, kadangi pasižymi žymiai didesniu patikimumu ir efektyvumu. Vaizdo apdorojimo metodai turi privalumų lyginant ir su mašininio mokymosi metodais, nes dažniausiai veikia greičiau nei sudėtingi dirbtinio intelekto metodai. Taip pat šie metodai dažnai yra naudojami kartu su dirbtinio intelekto metodais. Vaizdo apdorojimų metodų pagalba yra nustatoma regionas, kuris skiriasi nuo viso objekto, o mašininio mokymosi pagalba patikrinama, ar ši zona yra defektas.

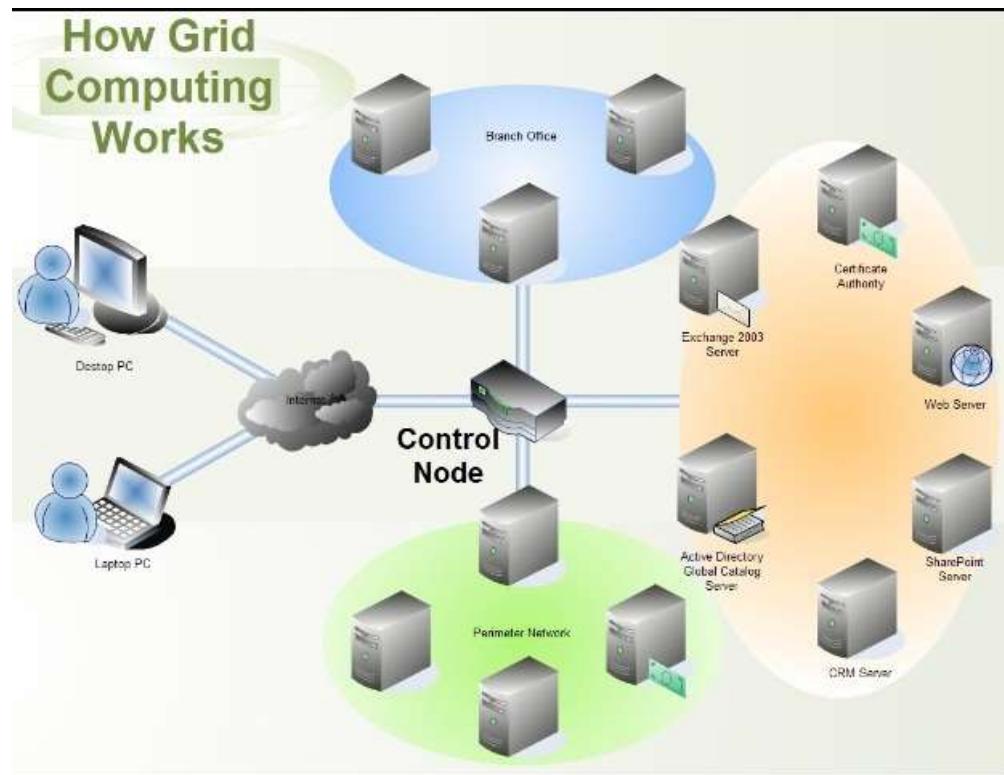
Vienspalvio ir tolygaus paviršiaus patikrai yra plačiai naudojami kraštų aptikimo algoritmai, kadangi šie algoritmai su dideliu patikimumu aptinka zonas, kurios skiriasi nuo tolygaus paviršiaus. Dažniausiai naudojamos kraštų aptikimo operacijos yra „Canny“, „Sobel“, „Roberts“, „Prewitt“, „Laplication“ ir „Kirsch“. [8] , [12]. Kurį algoritmą taikyti dažniausiai nustatoma pagal specifinę problemą. Kartais kai kurių metodų negalima taikyti, kadangi jie užtrunka per ilgai, yra per daug jautrūs triukšmams nuotraukose arba nėra tinkami aptiki mažiems defektams [12]. Aptikus defekto regioną reikia išgauti šio defekto savybes, pagal kurias galima nustatyti defekto tipą.

Išgaunamos šios savybės [12]:

- Kontrastas;
- Plotas;
- Perimetras;
- Koreliaciją;
- Gravitacijos centras;
- Apvalumas;
- Entropija;
- Vaizdo vidurkio reikšmė.

Pagal išgautas savybes galima nustatyti defekto tipą pasinaudojus mašininio mokymosi metodais.

Tradicinius vaizdo apdorojimo algoritmus galima pritaikyti ir gaminiam su tekstūra. Analizės metu buvo nustatyta, kad kraštų aptikimo algoritmai yra sėkmingai taikomi vidutinio tankio medienos plaušų plokštės (angl. Medium-density fibreboard) kokybės patikrai. [8] Realaus laiko kokybės patikros sistemoms yra labai svarbus defektų identifikavimo greitis ir atsako laikas, todėl norint sumažinti identifikavimo laiką galima panaudoti tinklinio skaičiavimo architektūrą. Šis metodas, kuris yra pavaizduotas **3.1 pav.** [13], leidžia padalinti visą nuotrauką į dalis ir kiekvienai daliai įvykdinti filrus bei kraštų aptikimo algoritmus atskirai. Nuotrauka yra padalinama į tiek dalį, kiek nenaudojamų resursų yra tuo metu. Norint, kad defektų nustatymų algoritmų tikslumas nesumažėtų dalinant nuotraukas jų kraštų iš visų pusų persidengia po 10 proc., kadangi prie kraštų gali būti labai mažų defektų. [8] Kiekvienas kompiuteris atlieka defektų aptikimo procesą su gauta vaizdo dalimi ir tada visų jų analizės rezultatai yra apjungiami ir pagal tai nusprendžiamą plokštės kokybę.



3.1 pav. Tinklinių skaičiavimų (angl. Grid computing) schema [13]

Tradiciniai vaizdo apdorojimo algoritmai dažnai gerai veikia defektų regionų nustatymui ir lokalizavimui, tačiau nepasižymi geru defektų charakterizavimu [14]. Defektų tipo nustatymas dažnai yra labai svarbus, kadangi nustačius defektų tipą galima žymiai lengviau nustatyti, kas sukelia šį defektą bei greičiau nustatyti gamybos proceso vietą, kurią reikia patobulinti ar pakeisti.

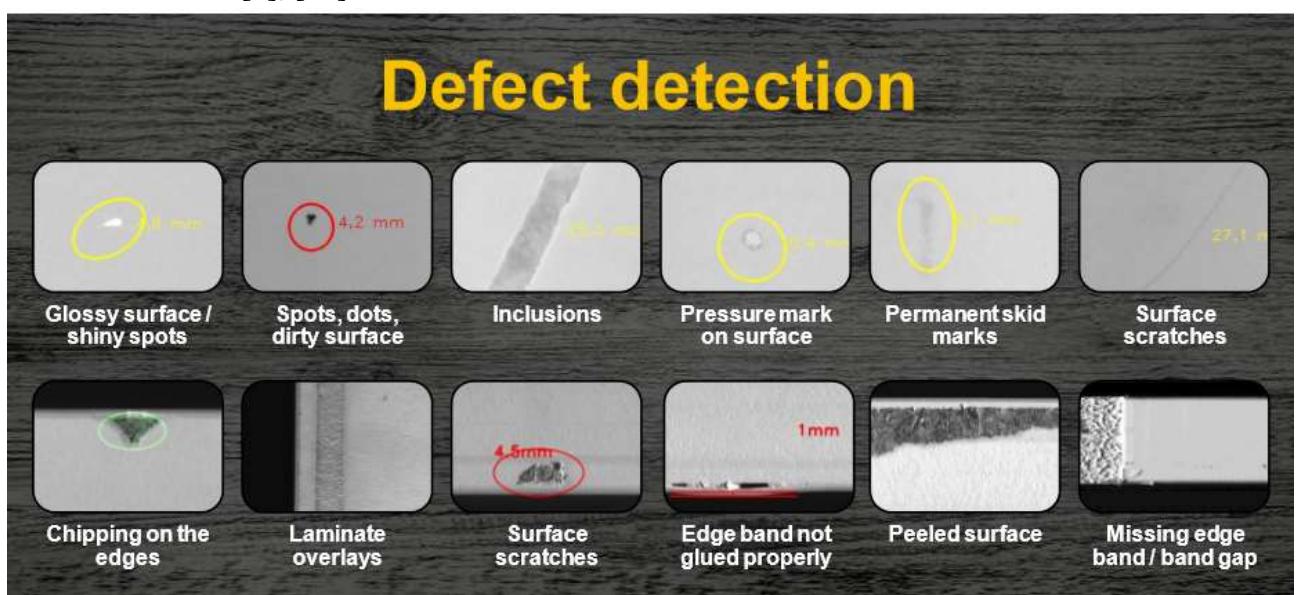
3.2. Mašininio mokymosi sprendimai defektų aptikimui

Mašininis mokymasis yra plačiai naudojamas sprendžiant vaizdų atpažinimo ir apdorojimo problemas. Kompiuterinės regos ir mašininio mokymosi naudojimas yra plačiai paplitęs daugumoje industrijos rūsių, kadangi šios technologijos beveik visada pranoksta kokybės patikros darbą atliekančius žmones [11]. Kompiuterinės regos ir mašininio mokymosi pagalba galima atlkti defektų identifikavimą, tekstūros ir formos klasifikavimą ir kitus patikros veiksmus tuo pačiu metu. Per pastaruosius dešimtmečius patikros sistemos padarė nemenką progresą sprendžiant tekstūros reguliavimo ir lygiavimo užduotis, tačiau didžiausią progresą pavyko pasiekti, kai buvo pradėti naudoti mašininio mokymosi algoritmai. Spendžiant mašininio mokymosi problemas yra naudojami du mašininio mokymosi algoritmų tipai: prižiūrimi ir neprižiūrimi. Prižiūrimi metodai yra po daugelio iteracijų sugeba sėkmingai nustatyti klases, pagal kurias buvo mokoma, o neprižiūrimi mašininio mokymosi metodai patys suformuoja grupes iš gautų duomenų [14]. Paviršiaus defektų identifikavimui ir klasifikavimui daugiausiai naudojami SVM ir KNN metodai. [2], [3], [11] Mašininio mokymosi naudojimas pramonės defektų aptikimui labai populiarėja ir vis daugiau problemų galima išspręsti panaudojant tinkamus metodus. Didelio populiarumo susilaukė ir „Kaggle“ puslapyje organizuotas konkursas [15], kurio metu dalyviai sukūrė ir padėjo patobulinti plieno paviršiaus defektų lokalizavimo ir defektų klasifikavimo algoritmus, kurie yra naudojami lyderiaujančios plieno gamybos įmonės „Severstal“

3.2.1. SVM metodo pritaikymas defektų tipo nustatymui

Dažnai defektų tipo nustatymui yra naudojami klasifikatoriai. Vienas populiariausiu yra atraminių vektorių klasifikatorius. Šis metodas yra populiarus, kadangi gali pasiekti didelį tikslumą nenaudojant daug skaičiavimų resursų, todėl dažnai yra naudojamas kokybės patikrai, kuri vyksta realiu laiku. [3], [16] SVM gali būti naudojamas regresijos ir klasifikavimo uždaviniams, tačiau plačiausiai naudojamas atliki klasifikavimą. SVM algoritmas yra pagrindžiamas statistinė šablonų atpažinimo teorija, apskritai atraminių vektorių klasifikatorius yra laikomas geresniu pasirinkimu triukšmingiemis duomenų rinkiniams, lyginant su „Naive Bayes“ ar neuroniniais tinklais, kalbant apie tikslumą ir skaičiavimų sudėtingumą [3]. Šio tyrimo metu SVM klasifikatorius pasiekė 90,5 proc. tikslumą, o dirbtinių neuroninių tinklų klasifikatorius pasiekė 89,9 proc. tikslumą. Atlikus vaizdų pradinį apdorojimą, kurio pagalba buvo pašalinti nuotraukų triukšmai, atraminių vektorių klasifikavimo metodas pasiekė net 94,4 proc. patikimumą, o tuo tarpu neuroninių tinklų algoritmas sugebėjo pasiekti 90,8 proc. tikslumą. [3] Taip SVM klasifikatorius pralenkė neuroninių tinklų metodą ne tik tikslumo atžvilgiu, bet savo mažesniu vykdymo laiku. [3]

Atraminių vektorių metodas yra sėkmingai naudojamas defektų aptikimui ir klasifikavimui medienos pramonėje. Vidutiniškai 96,5 proc. klasifikavimo tikslumas buvo pasiekta naudojant SVM klasifikatorių, kuris buvo apmokytas su 800 medienos mazgų nuotraukomis ir klasifikavo medienos mazgus net iki 5 grupes. [17] Norint nustatyti defektų tipą reikia išskirti dominuojančias defektų savybes. Šių savybių pasirinkimas ir išgavimas yra svarbiausias žingsnis, norint pasiekti sėkmingą defektų klasifikavimą. [17] Savybių išskyrimas yra vienas svarbiausių mašinorio mokymosi uždavinių, kuris padeda išvengti persimokymo (angl. overfitting) bei dimensijų prakeiksmo (angl. curse of dimensionality). [18] Dažnai tokios defektų savybės kaip spalva ir tekstūra yra labai svarbios žmogaus patikrai, tačiau naudojant kompiuterinės regos ir klasifikavimo metodus svarbiau yra santykis spalvos pokyčio su objekto fonu nei absoliutinė spalva, kadangi spalva gali labai priklausyti nuo kameros tipo bei nustatymų ir apšvietimo sąlygų. [17] Dažniausius baldų detalių paviršiaus defektus galima pamatyti **3.2 pav.**, šie defektai gana ryškiai skiriasi vienas nuo kito, todėl jų tipo nustatymui turėtų sėkmingai veikti SVM klasifikatorius, kadangi analizės metu nustatyta, kad šis klasifikatorius sėkmingai įvykdė panašias paviršiaus defektų tipų identifikavimo užduotis anksčiau minėtuose darbuose. [3], [17]

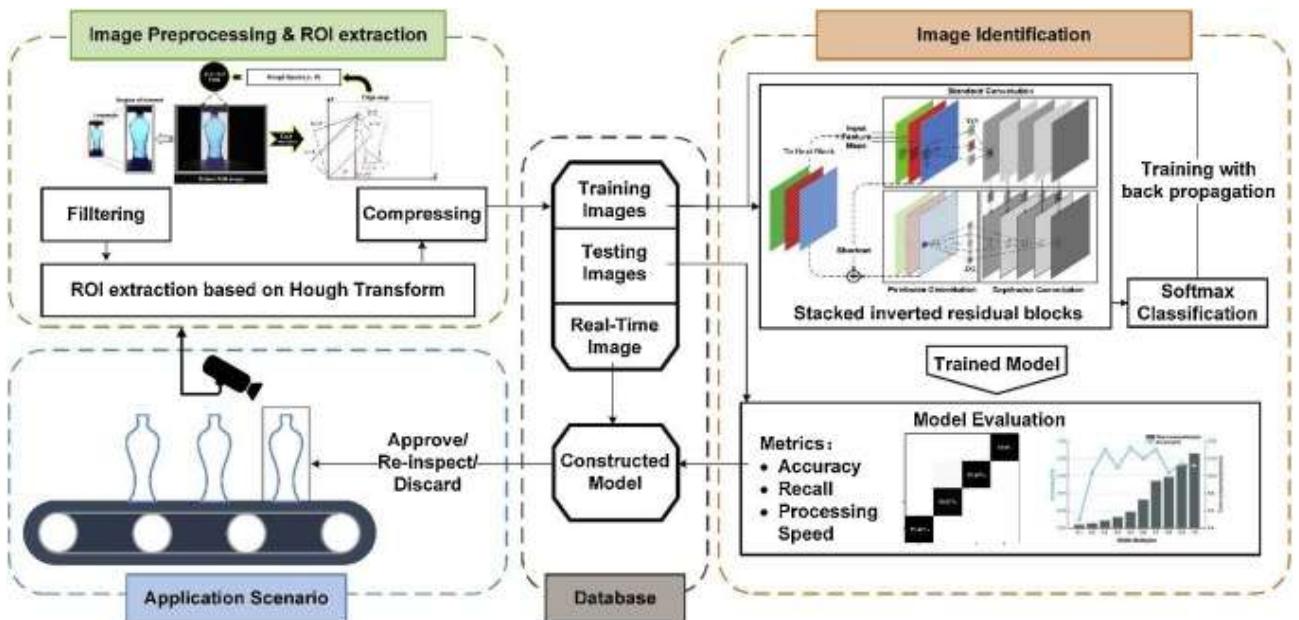


3.2 pav. Baldų detalių pagrindinių paviršių bei kraštų paviršių defektai, **UAB Elinta** nuotrauka

3.2.2. Konvoliucinių neuroninių tinklų taikymas defektų aptikimui ir klasifikavimui

Konvoliuciniai neuroniniai tinklai labai svarbus ir pastaraisiais metais labai išpopuliarėjęs vaizdų atpažinimo metodas, kuris sėkmingai pritaikomas taip pat ir pramoninės gamybos kokybės užtikrinimo bei defektų identifikavimo uždaviniuose. [19] Per keletą praėjusių metų panaudojant neuroninius tinklus buvo išspręsta daug įdomių bei svarbių problemų. Šie pasiekimai turi ne tik nemažai naudos mokslinių tyrimų atžvilgiu, bet dauguma yra pritaikomi realiame pasaulyje ir palengvina kasdieninį žmonių gyvenimą. Neuroninių tinklų taikymas labiausiai patobulėjo teksto vertimo, balso generavimo, vaizdo atpažinimo, savivaldžių automobilių bei sveikatos priežiūros srityse. [20] Didžiąją dalį šių pasiekimų ir privalumų galima pritaikyti sprendžiant gaminių defektų aptikimo bei klasifikavimo problemas.

Pastaraisiais metais kompiuterių skaičiavimo galia stipriai išaugo. Ypač didelę įtaką giliojo mokymosi populiarėjimui padarė stipriai padidėjusi grafinių procesorių sparta, todėl vis daugiau defektų aptikimo užduočių, atliekamų realiu laiku, galima išspręsti panaudojant konvoliucinius neuroninius tinklus, kurie dažnai pasižymi geresniais rezultatais nei kiti mašininio mokymosi metodai. Tačiau praktinėse didelių paviršiaus defektų ar plėvelės medžiagų patikros aplikacijose, kurios naudoja gilujį mokymąsi, šių metodų taikymas gali būti ne pats geriausias sprendimas dėl ypatingai didelių skaičiavimų resursų reikalavimų [2]. Giliojo mokymosi modelių tikslumas didėja didėjant modelių dydžiui, kuris tikrai sumažins apdorojimo greitį, todėl yra gana sudėtinga pasirinkti tinkamiausią patikros tikslumo bei skaičiavimų efektyvumo santykį [2]. Analizės metodu buvo nustatyta, kad kuriant sistemas, kurios aptinka objektus su defektais, nemažai dėmesio yra skiriama ne tik aparatūrinės įrangos tobulinimui, bet ir vaizdų apdorojimo bei defektų identifikavimo algoritmų optimizavimui bei efektyvumo didinimui [2]. Vienas siūlomas efektyvus variantas susideda iš trijų fazių. Pirmiausiai Gauso filtras panaudojamas triukšmų pašalinimui, tada „Hough“ transformacijos panaudojamos pašalinti nereikalingą foną ir gauti dominantį regioną (angl. Region of interest), galiausiai panaudojamas nesudėtingas giliojo mokymosi neuroninis tinklas, kuris panaudoja gautą regioną bei atpažista išskirto regiono klasę [2]. Šio metodo veikimo principas yra pavaizduotas **3.3 pav.**



3.3 pav. Butelių pažeidimų atpažinimo metodas [2]

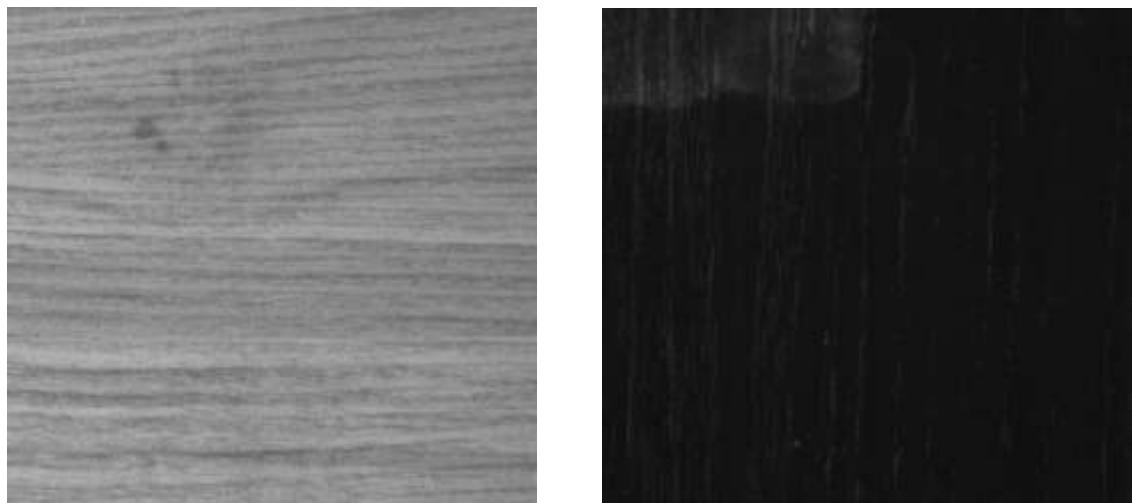
Šio tinklo svorių optimizavimui yra naudojamas atgalinės skaidos (angl. Backpropagation) algoritmas. Mokymosi fazės metu gana sudėtinga, bet svarbi užduotis yra nustatyti mokymosi greitį, kadangi netinkama mokymosi greičio reikšmė, taikant stochastinio gradiento nusileidimo optimizavimo algoritmą, gali įtakoti lėtesnius konvergavimą arba divergavimą, todėl šios užduoties palengvinimui buvo taikomas „Adam“ mokymosi greičio optimizatorius. [2] Pabaigus neuroninio tinklo mokymą ir atlikus spėjimus su testavimo duomenimis buvo gautas net 99,6 proc. tikslumas. [2] Tokio aukšto rezultato nepasiekė nei vienas anksčiau aprašytas SVM klasifikatorius, todėl galima teikti, kad KNN yra vienės geriausių sprendimų defektų klasifikavimui, tačiau jį vis dar stipriai riboja skaičiavimų trukmė. Atraminių vektorių ir konvoluciinių neuroninių tinklų bendrą palyginimą, paremtą analizės metu aprašytais rezultatais, galima rasti **1 lentelę**.

1 lentelė Konvoluciinių neuroninių tinklų ir atraminių vektorių klasifikatoriaus palyginimas

Kriterijus/Metodas	Konvoluciiniai neuroniniai tinklai	Atraminių vektorių klasifikatorius
Tikslumas	89,9 – 99,6 proc.	90,5 – 96,5 proc.
Galimybė pritaikyti tą patį modelį skirtingu paviršių analizei	Gana didelis efektyvumas	Mažas efektyvumas
Skaičiavimo resursai	Santykinai daug	Santykinai mažai
Reikalingas papildomas savybių išskyrimas	Ne	Taip
Mokymo trukmė	Ilgai	Trumpai
Spėjimo atlikimo trukmė	Santykinai ilgai	Santykinai trumpai
Duomenų kiekis apmokymui	Santykinai daug	Santykinai mažai

Kiti svarbi problemi, kurią galima išspręsti pasinaudojus konvoluciinių neuroninių tinklų pagalba yra paviršių defektų aptikimas paviršiuose su ryškia struktūra. Keletas baldų detalių nuotraukų su ryškia tekštūra pavaizduota **3.4 pav.Klaida! Nerastas nuorodos šaltinis.**, aptiki tam tikrus defektus

šiuose paviršiuose yra ypatingai sudėtinga, kadangi įbrėžimai arba nutrynimai yra labai panašūs į tekstūrą. Analizės metu nustatyta, kompiuterinės regos ir mašininio mokymosi technologijos seniau buvo naudojamos tik lygaus paviršiaus defektų nustatymui, tačiau šiuo metu pažengę giliojo mokymosi metodai gali analizuoti paviršius su sudėtinga tekstūra ar net atliliki tekstūros reguliavimo bei lygiavimo matavimo užduotis. [11]



3.4 pav. Baldų detalės su ryškia tekstūra, **UAB Elinta** nuotrauka

Konviliuciniai neuroniniai tinklai yra sudaryti iš įvesties, išvesties bei daug paslėptų sluoksnių. Bendras neuroninių tinklų rezultatas priklauso nuo paslėptų sluoksnių sudėties, todėl labai svarbu optimaliai sudaryti šiuos sluoksnius. Kai svorių apmokymui yra naudojami gana geri duomenys bei yra didelis duomenų kiekis, galima išgauti aukštesnio lygmens duomenų savybes sujungiant žemesniojo lygmens išvesties charakteristikas. [11] Paviršiaus patikrai yra labai svarbu pasirinkti tinkamą pavyzdinių nuotraukų dydį, nes šie vaizdai turi būtų pakankamai dideli, kad iš jų būtų galima nustatyti mažus defektus bei tekstūrą, todėl analizės metu nustatyta, kad dažniausiai norint išmokti tekstūrą yra naudojami 32 pikselių ilgio ir 32 pikselių pločio vaizdai. [11] Šio eksperimento metu naudojami net 6 skirtingo tipo paviršiai, šio tyrimo rezultatai buvo palyginti su vizualine žmogaus patikrą, ši palyginimą galima pamatyti **2. lentelė**. [11] Palyginime matome, kad tikslumas yra labai panašus, tačiau visuose kituose kriterijuose tiriamas metodas žymiai pranoksta žmogaus patikros metodą, todėl galima teigt, kad mašininio metodas yra ženkliai pranašesnis.

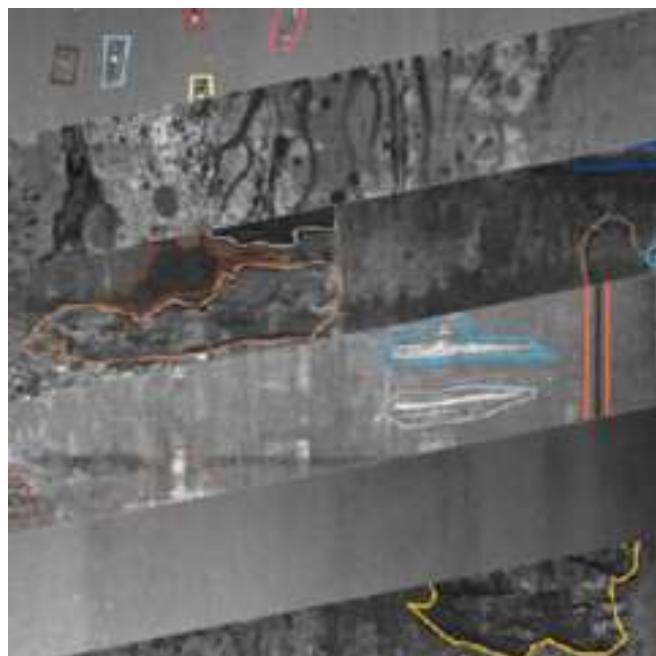
2. lentelė Žmogaus vizualinės patikros bei tyrimo aprašyto metodo palyginimas

Kriterijus/Metodas	Siūlomas metodas	Žmogaus vizualinė patikra
Tikslumas	98 proc.	98,5 proc.
Greitis	5285 pavyzdžiai per minutę	20 pavyzdžių per minutę
Darbo trukmė	Visą dieną	Ribotos valandos
Defektų tipai	Įvairūs	Tik specifiniai defektai

3.2.3. „Kaggle“ platformos apžvalga

Pramoninės gamybos kokybės patikros uždaviniai yra sprendžiami net „Kaggle“ konkursų metu. „Kaggle“ platforma yra labai populiarė tarp duomenų analitikų bei dirbtinio intelekto tyrėjų, nes didžioji dalis šių žmonių turi tik teorinių žinių ir retai susiduria su realaus pasaulio iššūkiais prieš pradėdami dirbti. 2017 metais ši platforma turėjo virš 500 tūkstančių aktyvių narių, kurie aktyviai bendravo, bendradarbiavo bei varžėsi, sprendžiant realaus pasaulio problemas. [21] Šių konkursų metu tyrėjai gauna ne tik neįkainojamų žinių, bet geriausiu sprendimui autoriai yra apdovanojami gana dideliais piniginiai prizais. Šios platformos bendruomenė sparčiai auga, čia naudingos informacijos ras ne tik pradedantys mašininio mokymosi entuziastai, bet ir pažengę dirbtinio intelekto tyrėjai.

Ypatingai didelio populiarumo susilaukė plieno paviršiaus defektų aptikimo konkursas, kurį organizavo „Severstal“ įmonė, šio konkurso defektų nuotrauką galite pamatyti **3.5 pav.** Šios užduoties sprendime dalyvavo virš 2000 komandų, bendras prizinis fondas buvo net 120 tūkstančių JAV dolerių [15]. Įmonė siekia panaudoti mašininio mokymosi sprendimus, kurie pagerins automatizacijos lygi, padidins gamybos efektyvumą ir palaikys aukštą jų produktų kokybę. Tiksliausi bei efektyviausiai „Kaggle“ konkurso algoritmai dažnai yra pritaikomi įmonių, kurios inicijuoja šiuos konkursus, taikomosiose programose.



3.5 pav. Plienų paviršiaus defektai [15]

4. Egzistuojančių rinkoje sistemų savybių palyginimas

Rinkoje egzistuoja nemažai įmonių, kurios pasitelkia kompiuterinės regos technologijas pramonės gaminių patikrai, tačiau nėra gausu baldų detalių kokybės užtikrinimo sistemų, kadangi jas sukurti yra gana sudėtinga ir užtrunka daug laiko. Analizės metu nustatyta, kad populiariausiai yra įmonės „Baumer Inspection GmbH“ kuriamas sprendimas „ColourBrain“ [22] bei „Argos Solution“ sistema „Argos Grading System“ [23]. Abi sistemos yra modulinės ir gali būti sukonfigūruojamos pagal kliento poreikius. Analizės metu nustatyta, kad abi sistemos gali tikrinti visų detalių paviršiaus defektus, gręžtinių skylių bei griovelio pozicijos bei geometrijos neatitinkamus, tačiau pavyko rasti informaciją tik apie „ColourBrain“ sprendimo naudojamus metodus. „Baumer Inspection GmbH“ įmonė paviršiaus defektų aptikimo problemai net sukurė specialias kameras, kuriose vykdomas tam tikras pirminis vaizdo apdorojimas [24].

3 lentelė. „ColourBrain“ ir „Argos Grading System“ sistemų palyginimas [22], [23], [24]

Kriterijus/Sistema	ColourBrain	Argos Grading System
Defektų klasifikavimas	Taip	Taip
Greitis	100 m/min	100m/m
Skylių ir griovelio patikra	Taip	Taip
Kraštų defektų patikra	Taip	Taip
Paviršių patikra	Taip	Taip
Defektų kilmės nustatymas	Taip	Ne
Minimalus defektų dydis	0,2 mm	1mm ²
Spalvotų kamerų naudojimas paviršių defektų nustatymui	Taip	Nepateikiama
Lazerio naudojimas	Taip	Taip
Skirtingų tekstūrų analizė	Taip	Taip
Statistinė informacija gamybos optimizavimui	Taip	Taip
Pirminis vaizdo apdorojimas kameroje	Taip	Nepateikiama
Aparatūrinės ir programinės įrangos sprendimai	Taip	Taip
Linijos nuskaitymo kameros	Taip	Taip
Mašininio mokymosi metodai	Atraminių vektorių klasifikatorius	Nepateikiama

Abi sistemos turi panašias funkcijas, tačiau „ColourBrain“ sistema daugiau dėmesio skiria defektų kilmės nustatymui ir gamybos proceso optimizavimui, šios savybės palyginamos **3 lentelėje**. Taip „Baumer Inspection GmbH“ siūlomas sprendimas naudoja spalvotas linijos nuskaitymo kameras,

kurių pagalba galima gauti tikslesnius duomenis apie skirtinges tekstūras. Vykdant analizę buvo nustatyta, kad įmonė „Baumer Inspection GmbH“ net patentuoja savo technologinius sprendimus [7], [24]. „ColourBrain“ sistema pasinaudoja vaizdo apdorojimo metodais aptikti defektus, o vėliau klasifikuoja defektus pagal jų kilmės šaltinį, pasinaudodama „Q-brain“ klasifikatoriumi, kuris yra paremtas atraminių vektorių klasifikatoriumi.

Išvados

1. Analizės metu buvo patvirtinta, kad pramonės automatizavimas užima labai svarbią vietą šiuolaikinės gamybos procesų grandinėje ir tik pramonės automatizavimas kartu su kompiuterinės regos technologijomis gali užtikrinti pažangią gamybą.
2. Analizės metu patvirtinta, kad placių paviršių nuotraukų nuskaitymui dažniausiai yra naudojamos linijos nuskaitymo kameros, kurios dirba dideliu greičiu ir pasižymi didelės skiriamosios gebos vaizdais.
3. Mašininio mokymosi algoritmai yra labai populiarūs gaminių patikros sprendimuose, tačiau ne visada metodai, kurie pasižymi didžiausiu tikslumu, yra pakankamai greiti, kad jų pagalba būtų galima vykdyti patikrą realiu laiku, todėl būtina juos optimizuoti, išlaikant kuo didesnį tikslumą.
4. Analizės metu nustatyta, kad populiariausi atraminių vektorių klasifikatoriaus bei konvoliucinių neuroninių tinklų metodai, tačiau konkretus pasirinkimas priklauso nuo techninės įrangos bei kitų apribojimų.
5. Paviršiaus defektų identifikavimo ir klasifikavimo problemai spręsti dažnai naudojami tradiciniai vaizdo apdorojimo algoritmai, kurie nustato defekto vietą, o tik vėliau mašininio mokymosi algoritmuli pagalba nustatomas defektų tipas. Ši principą galima pasitelkti kuriamame sprendime, kadangi tai sumažina bendrą analizės trukmę, tačiau užtikrina didelį tikslumą.
6. Konvoliuciniai neuroniniai tinklai yra pranašesni nei kiti mašininio mokymosi algoritmai, kadangi vieną modelį galima apmokyti taip, kad jis pakankamai dideliu tikslumu nustatytų objektų su skirtingomis tekstūromis paviršiaus defektus. Baldų detalės pasižymi plačia tekstūrų gama, todėl konvoliucinių tinklų pagalba galima taikyti tą patį metodą visoms tekstūroms ir sumažinti algoritmuli rašymo trukmę.
7. Viena pirmaujančių rinkos įmonių „Baumer Inspection GmbH“ naudoja atraminių vektorių klasifikatorių, kurio pagalba nustato defekto kilmės šaltinių.

Literatūros sąrašas

- [1] H. Chen, S. Stavinoha, M. Walker, B. Zhang ir T. Fuhlbrigge, „Opportunities and Challenges of Robotics and Automation in Offshore Oil & Gas Industry,“ SciRes, 2014.
- [2] J. Wang, P. Fu ir R. X. Gao, „Machine vision intelligence for product defect inspection based on deep learning and Hough transform,“ Journal of Manufacturing Systems, 2019.
- [3] H. Jia, Y. Murphey, J. Shi ir T.-S. Chang, „An intelligent real-time vision system for surface defect detection,“ IEEE, 2004.
- [4] R. Wakamatsu, T. Uno ir H. Katagiri, „Machine Learning-based Methods for Detecting,“ įtraukta *Proceedings of the World Congress on Engineering 2018 Vol I*, London, 2018.
- [5] C.-S. Cho, B.-M. Chung ir M.-J. Park, „Development of real-time vision-based fabric inspection system,“ IEEE, 2005.
- [6] „Line scan cameras - Quality right down the line,“ STEMMER IMAGING, 2018. [Tinkle]. Available: <https://www.stemmer-imaging.com/en/technical-tips/line-scan-cameras/>. [Kreiptasi 15 lapkričio 2019].
- [7] J. EBERHARDT ir R. Massen, „Method and arrangement for visual surface inspection“. Vokietija Patentas WO2010081509A1, 22 liepos 2010.
- [8] A. J. S. Santiago, A.J., Yuste, A.J ir M. Expósito, „Real-time image texture analysis in quality management using grid computing: an application to the MDF manufacturing industry,“ Springer-Verlag, 2011.
- [9] B. Bennedsen ir D. Peterson, „Performance of a System for Apple Surface Defect Identification in Near-infrared Images,“ Biosystems Engineering, 2005.
- [10] I. Pastor-Lopez, I. Santos, Jorge, M. Salazar, A. Santamaria-Ibirika ir P. Bringas, „Collective classification for the detection of surface defects in automotive castings,“ įtraukta *Industrial Electronics and Applications (ICIEA), 2013 8th IEEE Conference on*, 2013.
- [11] J.-K. Park, B.-K. Kwon, J.-H. Park ir D.-J. Kang, „Machine learning-based imaging system for surface defect inspection,“ Korean Society for Precision Engineering, 2016.
- [12] B. Tang, J.-y. Kong, X.-d. Wang ir L. Chen, „Surface Inspection System of Steel Strip Based on Machine Vision,“ IEEE, 2009.
- [13] D. Thakur, „What is Grid Computing,“ Ecomputer Notes, 2018. [Tinkle]. Available: <http://ecomputernotes.com/fundamental/introduction-to-computer/grid-computing>. [Kreiptasi 10 lapkričio 2019].
- [14] A. Bernieri, L. Ferrigno , M. Laracca ir M. Molinara, „Crack Shape Reconstruction in Eddy Current Testing Using Machine Learning Systems for Regression,“ IEEE, 2008.
- [15] „Severstal: Steel Defect Detection,“ Kaggle, 2019. [Tinkle]. Available: <https://www.kaggle.com/c/severstal-steel-defect-detection>. [Kreiptasi 19 lapkričio 2019].

- [16] R. Gandhi, „Support Vector Machine — Introduction to Machine Learning Algorithms,“ Towards Data Science, 7 birželio 2018. [Tinkle]. Available: <https://towardsdatascience.com/support-vector-machine-introduction-to-machine-learning-algorithms-934a444fca47>. [Kreiptasi 18 lapkričio 2019].
- [17] I. Y.-H. Gu, H. Andersson ir R. Vicen, „Wood defect classification based on image analysis and support vector machines,“ Springer-Verlag, 2009.
- [18] G. Azevedo, „Feature selection techniques for classification and Python tips for their application,“ Towards Data Science, 2 rugpjūčio 2019. [Tinkle]. Available: <https://towardsdatascience.com/feature-selection-techniques-for-classification-and-python-tips-for-their-application-10c0ddd7918b>. [Kreiptasi 19 lapkričio 2019].
- [19] L. A. Martins, F. L. Pádua ir P. E. Almeida, „Automatic detection of surface defects on rolled steel using Computer Vision and Artificial Neural Networks,“ IEEE, 2010.
- [20] S. Weidman, „The 4 Deep Learning Breakthroughs You Should Know About,“ Towards Data Science, 5 gruodžio 2017. [Tinkle]. Available: <https://towardsdatascience.com/the-5-deep-learning-breakthroughs-you-should-know-about-df27674ccdf2>. [Kreiptasi 20 lapkričio 2019].
- [21] Z.-u.-h. Usmani, „What is Kaggle, Why I Participate, What is the Impact?,“ Kaggle, 2017. [Tinkle]. Available: <https://www.kaggle.com/getting-started/44916>. [Kreiptasi 15 lapkričio 2019].
- [22] „Standard or individual solutions for your furniture production,“ Baumer Inspection GmbH, 2018. [Tinkle]. Available: <https://www.baumerinspection.com/en/products/surface-inspection/furniture/>. [Kreiptasi 19 lapkričio 2019].
- [23] „Grading System,“ Argos Solution, 2017. [Tinkle]. Available: <https://www.argossolutions.no/grading-system/>. [Kreiptasi 19 lapkričio 2019].
- [24] „Optimization of Production in Short Cycle Press Lines,“ Baumer Inspection GmbH, 2016. [Tinkle]. Available: <http://pelice-expo.com/presentations/Franz-Optimization-of-Production.pdf>. [Kreiptasi 20 lapkričio 2019].